

NLP Text Mining ATLAS

Analyse régionale des offres d'emploi

université
Lumière
LYON 2

Cyrille PECNIK - Mohamed Riad SAHRANE - Olivier BOROT



Introduction à l'application

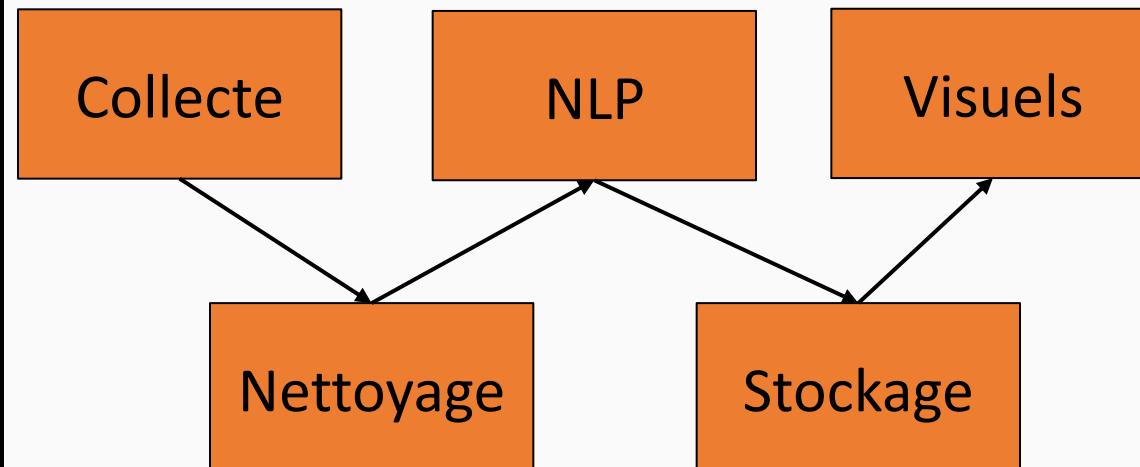
Constat

Les offres d'emploi sont :

- Dispersées
- Non structurées
- Difficile à analyser globalement

Solution

Pipeline automatisé complet



Résultat

- 5000 offres collectées
- 35000 communes géolocalisées
- 8 thèmes
- 384 dimensions d'embeddings

Sommaire

- ▶ Données utilisées
- ▶ Entrepôt de données
- ▶ Web application Streamlit
- ▶ Dockerisation
- ▶ Analyses
- ▶ Bilan critique



Données utilisées



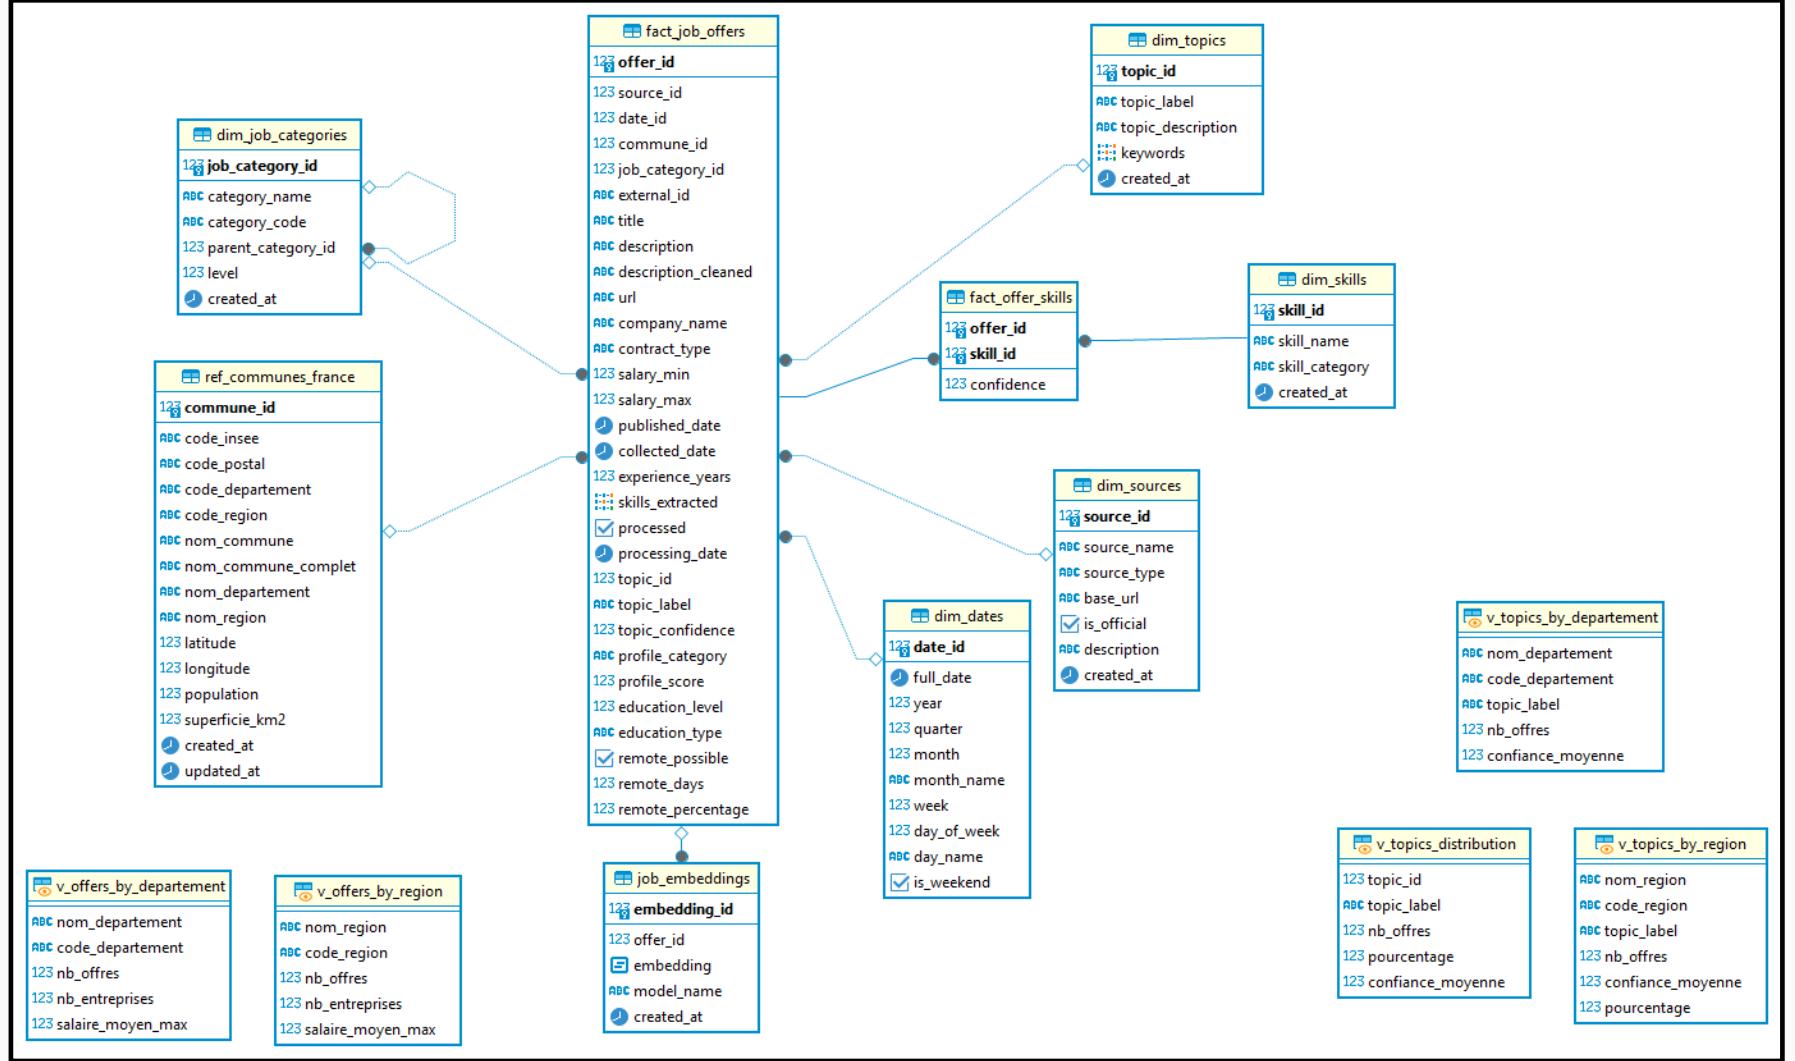
France Travail

- Données structurées
- API OAuth2
- Limite de 3000 offres/requête
- Coordonnées fournies

Welcome to the Jungle

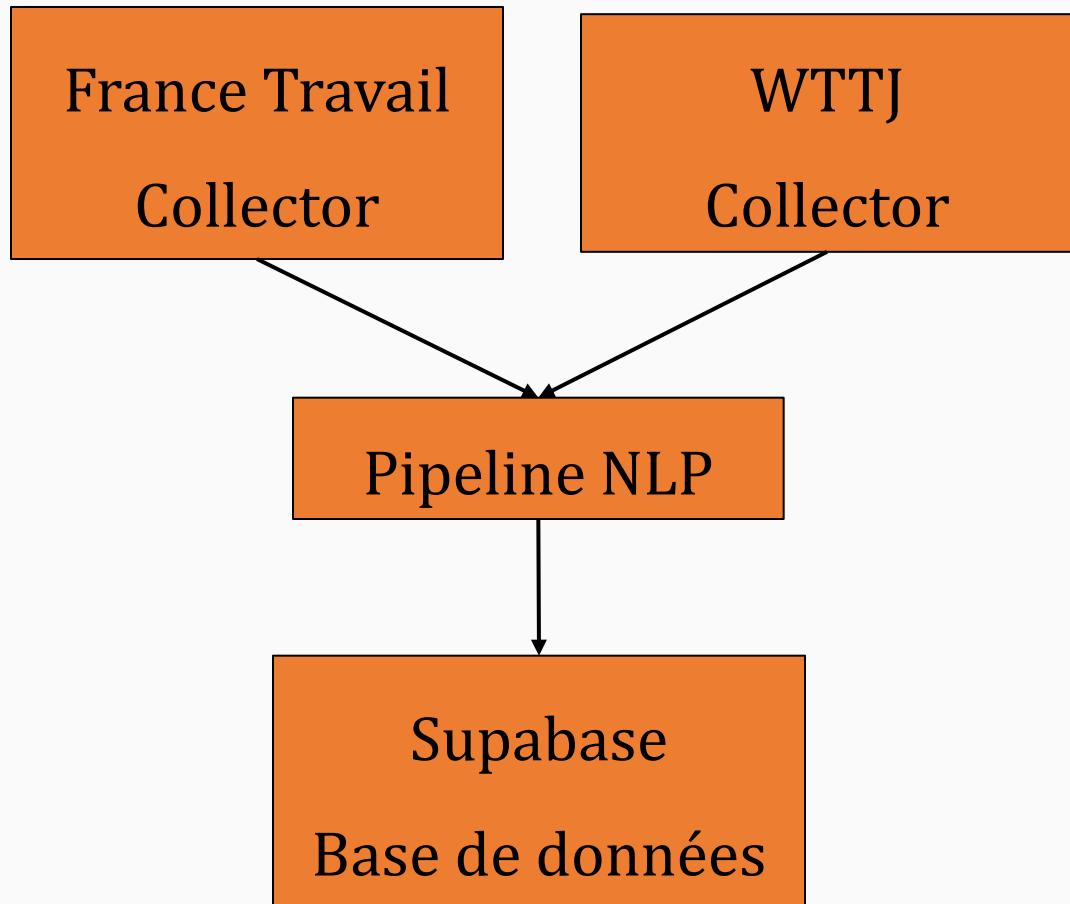
- Web Scraping Selenium
- Aucune
- Dépend du scrolling infini
(environ 500 offres)
- Géocodage nécessaire

Entrepôt de données



- Base de données **Supabase** (PostgreSQL)
- Modèle en étoile
- dimensions :
 - Topics,
 - Skills,
 - Sources,
 - Temps,
 - Localisation,
 - Catégorie métier

Entrepôt de données



Atouts :

- Sauvegarde locale (dédoublement)
- Enrichissement NLP
- Coordonnées GPS géocodés si non disponibles
- Détection des doublons
- Bonne gestion des vecteurs par PostgreSQL

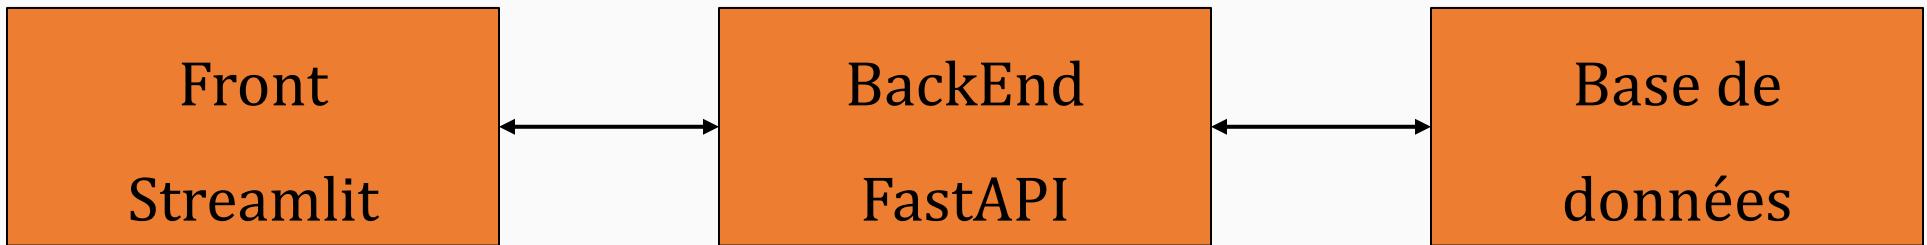
Risques pour la pérennité :

- Changement de l'API
- WTTJ peut bloquer le scraping
- Coûts pour Supabase pour scale

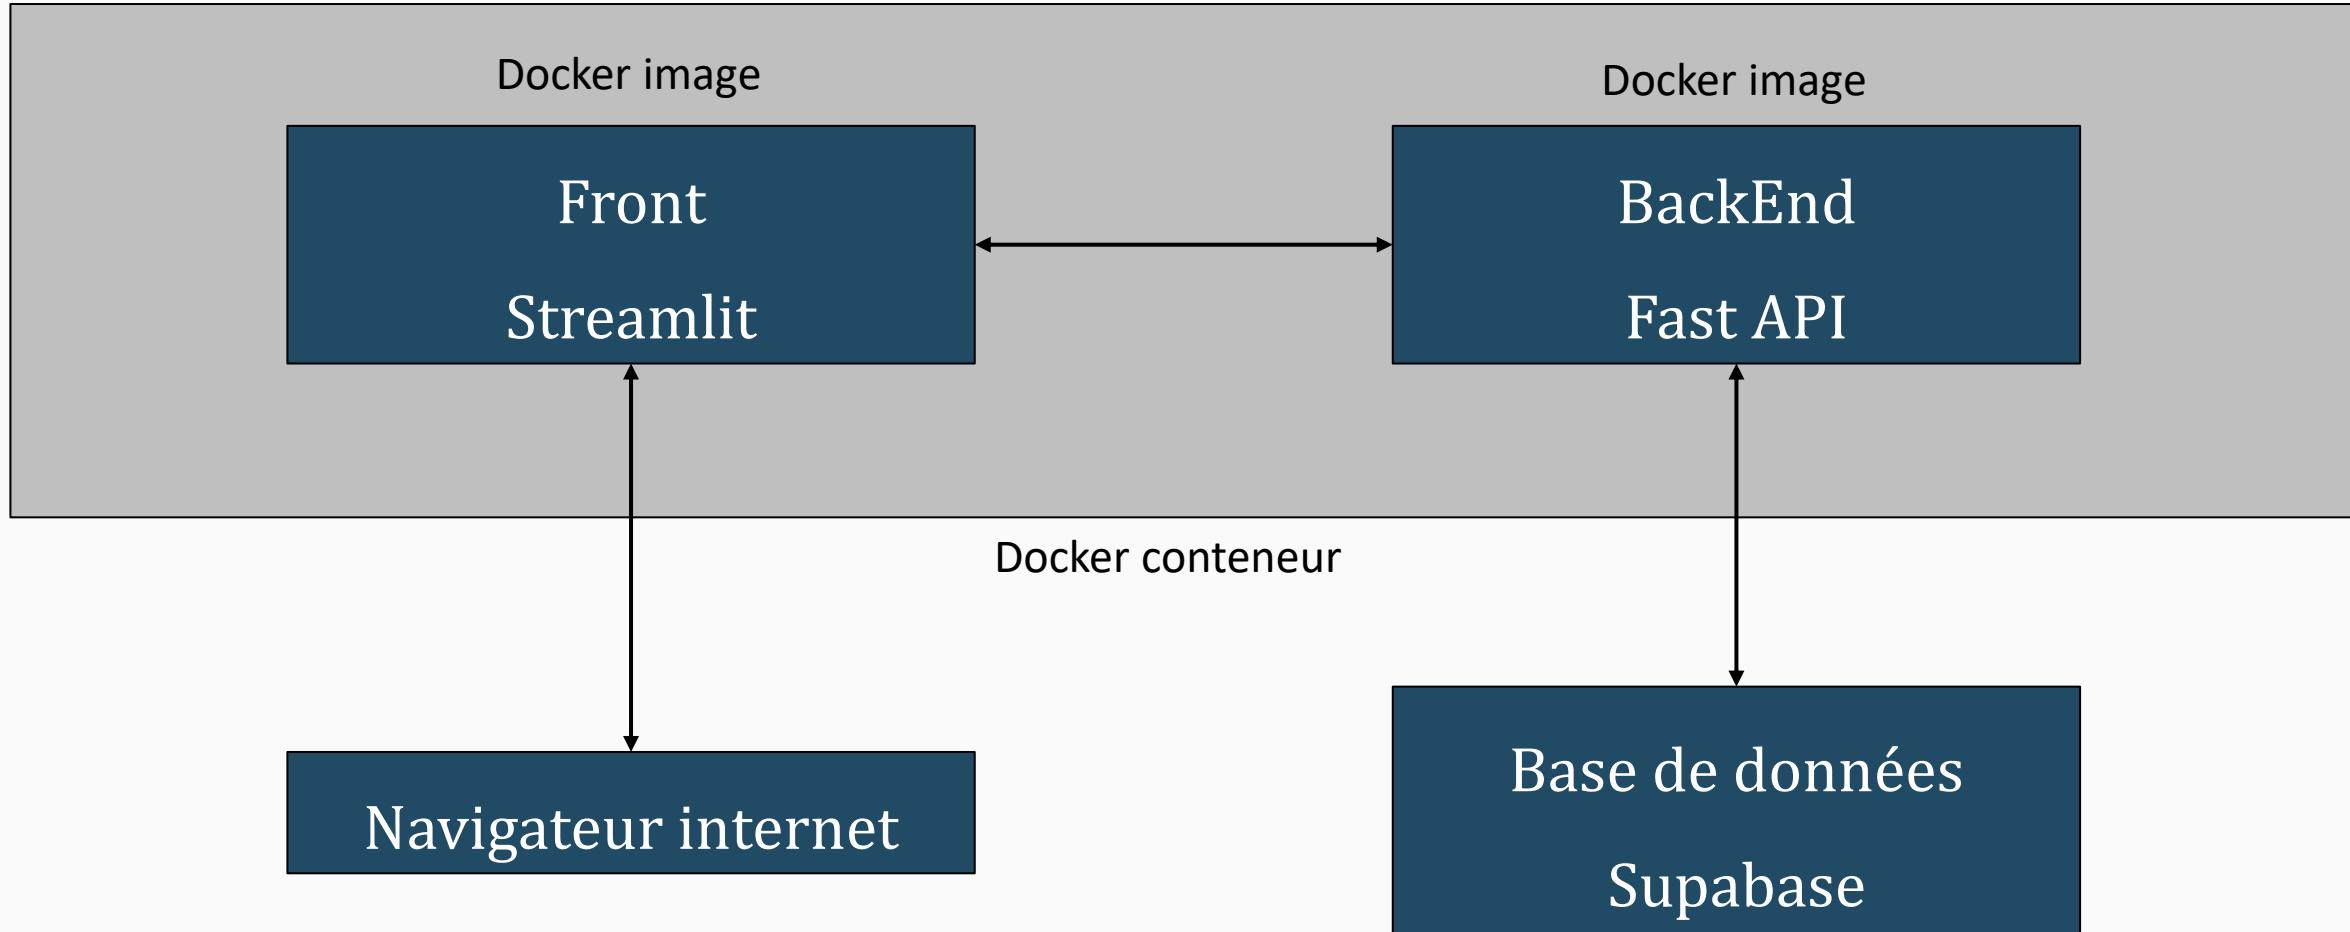
Web app. Streamlit



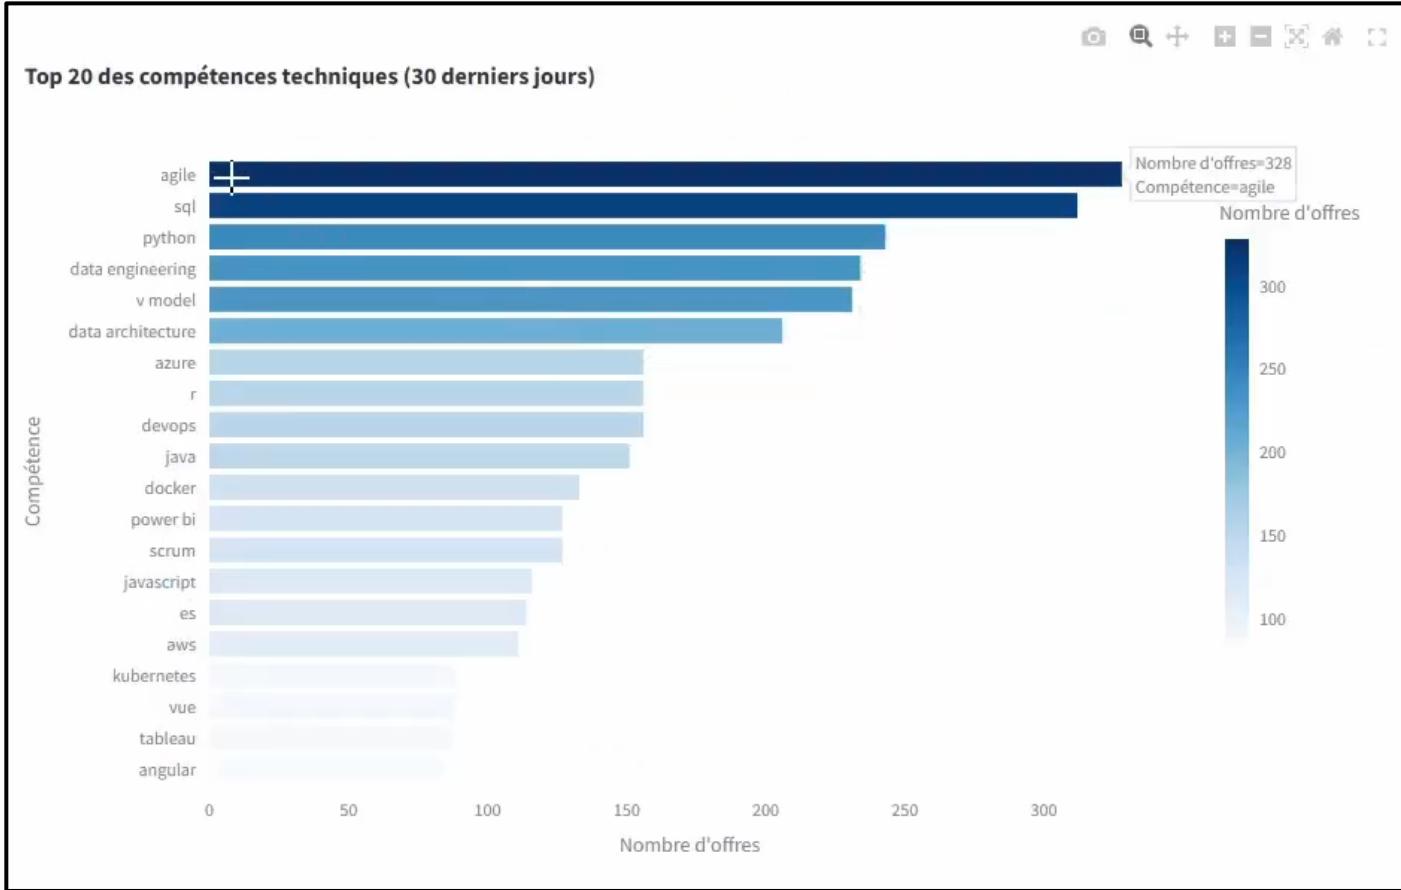
Dashboard : KPIs principaux, répartition par source/contrat
Carte : Visualisation géographique des offres (Folium)
Comparaisons : Comparaison Data Analyst vs Data Scientist vs Data Engineer
Tendances : Évolution temporelle des offres et salaires
Administration : Lancement manuel de la collecte, enrichissement NLP



Dockerisation



Analyses



Analyses simples :

- Nombre d'offres collectée
- Répartition par sources
- Répartition par types de contrat ...

Analyses géographiques :

- Par région / département / ville

Analyses NLP :

- Compétences les plus demandées
- Soft skills
- Évolution dans le temps



Bilan critique

- ▶ Application efficace, Streamlit + API, enrichissements NLP
 - ▶ Excellente base pour continuer à itérer et rajouter des améliorations
-

Possibilités d'ajouter :

- ▶ Scores de profil, score de qualité de l'offre ...
- ▶ Analyses de biais, salariale avec benchmarks, de sentiment de l'offre ...
- ▶ Enrichissement avec Glassdoor, nouvelles APIs, résumés d'offres ...
- ▶ Détection de biais, de phrases problématiques, de contrats illégaux ...
- ▶ Chatbot RAG ...

Merci de nous
avoir écouté.

